



Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Estado de México

Momento de Retroalimentación: Módulo 2 Análisis y Reporte sobre el desempeño del modelo. (Portafolio Análisis)

Alberto Gallegos Hernández A01752303

Inteligencia artificial avanzada para la ciencia de datos (Grupo 601)

Prof. Jorge Adolfo Ramírez Uresti

Miércoles 16 de septiembre del 2026

Resumen del entregable

Se aplicó regularización a un modelo Random Forest. Restricción de profundidad ($\text{max_depth} = 5$) y selección de features ($\text{max_features} = \text{'log2'}$) redujo el gap train-test de 8.8% a 7.0%. Test accuracy: 92.1% vs 91.2% baseline.


Metodología

- Datos: 569 muestras, 30 características, split 60/20/20 estratificado.
- Baseline: Random Forest $\text{max_depth} = \text{None}$, 100 estimadores.
- Tuning: GridSearchCV 5-fold CV. Óptimo: $\text{max_depth} = 5$, $\text{max_features} = \text{'log2'}$.

Resultados Numéricos

Conjunto	Baseline	Regularizado	Cambio
Entrenamiento	1.0000	0.9912	-0.0088
Validación	0.9649	0.9649	+0.0000
Test	0.9123	0.9211	+0.0088
Gap Train-Test	0.0877	0.0701	-0.0176

Figura 1: Comparación de Accuracy



Análisis Visual

Figura 2: Matrices de confusión





Figura 3: Curva de aprendizaje, baseline



Curvas del Modelo Regularizado

Figura 4: Curva de aprendizaje, regularizado





Figura 5: Curva de validación, max_depth



Análisis de Sesgo y Varianza

Diagnóstico del Modelo

Indicador	Baseline	Regularizado	Evaluación
Bias	Bajo	Bajo	Ambos bajo
Varianza	Alto	Medio	Reducida
Ajuste	Overfitting	Fitting óptimo	Mejora
Gap	8.8%	7.0%	Reducido 1.8%

1. Grado de Bias (Sesgo): Bajo en ambos modelos

El modelo baseline alcanza accuracy del 100% en entrenamiento y el regularizado 99.1%, ambos valores muy altos que indican bajo sesgo. El sesgo mide la capacidad del modelo para aprender patrones complejos; un sesgo bajo significa que el modelo no es demasiado simple y puede representar correctamente la relación entre las 30 características del cáncer (tamaño, textura, simetría, etc.) y su clasificación final. Un modelo con alto sesgo (underfitting) no alcanzaría estos niveles de accuracy en entrenamiento. Por el contrario, ambos modelos demuestran suficiente flexibilidad para aprender los patrones genuinos en los datos de cáncer de mama, por lo que el problema observado no es la incapacidad de aprender, sino la capacidad de aprender demasiado, incluyendo ruido, lo cual es un problema de varianza.

2. Grado de Varianza: Alto (Baseline): Medio (Regularizado)

La varianza se mide observando el gap entre rendimiento en entrenamiento y test. El baseline tiene un gap de 8.8 puntos porcentuales (100% - 91.2%), indicando varianza alta: el modelo alcanza perfección en entrenamiento pero cae significativamente en datos nuevos. Esto ocurre porque sin restricción en profundidad (max_depth=None), los árboles memorizan detalles específicos del conjunto de entrenamiento. El modelo regularizado reduce este gap a 7.0% (99.1% - 92.1%), logrando varianza media. La Figura 3 muestra que la línea de validación cruzada del baseline oscila erráticamente entre 94-96%, mientras que la Figura 4 muestra que la del regularizado es mucho más suave y consistente, confirmando la reducción de varianza. Esta reducción de 1.8 puntos en el gap es significativa porque indica que el modelo regularizado generaliza mejor a datos nuevos: la brecha entre entrenamiento y test es más pequeña y esperada, no una caída catastrófica.

3. Nivel de Ajuste del Modelo: Overfitting: Fitting Óptimo

El modelo baseline sufre overfitting: memoriza ejemplos específicos del entrenamiento en lugar de aprender patrones generales. Un árbol sin restricción puede crear ramas ultra-específicas como 'si concavidad=0.165 Y simetría=0.28 Y radio=18.5, entonces maligno', que funcionan perfectamente en entrenamiento pero no generalizan. La Figura 5 (curva de validación) muestra claramente este problema: el accuracy de entrenamiento sigue subiendo conforme aumenta max_depth, pero el de validación se estabiliza alrededor de 96.2%, evidenciando que árboles más profundos solo aprenden

ruido específico de entrenamiento. El modelo regularizado, con `max_depth=5`, logra fitting óptimo: es lo suficientemente complejo para aprender patrones reales (bajo sesgo confirmado por 99.1% en entrenamiento) pero lo suficientemente simple para no memorizar ruido (baja varianza confirmada por gap controlado de 7.0%). Este balance es exactamente lo que buscamos en machine learning, permitiendo mayor confianza en el rendimiento del modelo con datos completamente nuevos.

4. Técnicas de Regularización Aplicadas

Se aplicaron cuatro técnicas de regularización de forma integrada. `Max_depth=5` limita la profundidad de los árboles, previniendo que crezcan tan profundamente que memoricen datos de entrenamiento específicos. `Max_features='log2'` introduce diversidad al considerar solo $\sqrt{30} \approx 5$ características aleatorias en cada nodo, impidiendo que los árboles coordinen sus decisiones sobre características raras o ruidosas. La validación cruzada (5-fold CV) en `GridSearchCV` proporciona una selección robusta de hiperparámetros: en lugar de basarse en una sola división, usa el promedio de 5 evaluaciones diferentes, reduciendo la varianza en la selección de parámetros. Finalmente, la estratificación mantiene la proporción de clases (malignos vs benignos) en cada conjunto, evitando sesgos por distribución desigual. Estas técnicas trabajan sinérgicamente: `max_depth` reduce complejidad, `max_features` añade estabilidad, CV asegura robustez, y estratificación evita sesgos. El resultado es un modelo más confiable con mejor generalización.

Conclusiones

1. Evaluación con Conjunto de Prueba y Validación

Se implementó una estrategia rigurosa con tres conjuntos independientes: 60% entrenamiento (341 muestras), 20% validación (114 muestras) y 20% test (114 muestras), todos divididos de forma estratificada para mantener la distribución de clases. El conjunto de validación se utilizó en validación cruzada (5-fold) durante `GridSearchCV` para seleccionar hiperparámetros sin contaminar el test set. El conjunto de test se mantuvo completamente independiente, nunca visto por el modelo durante entrenamiento ni usado para tomar decisiones de hiperparámetros, garantizando una evaluación honesta del rendimiento esperado en datos completamente nuevos.

2. Detección Correcta del Grado de Bias: Bajo

Se detectó correctamente que ambos modelos (baseline y regularizado) tienen sesgo bajo, evidenciado por accuracy de 100% y 99.1% respectivamente en entrenamiento. Estos valores altos confirman que los modelos tienen la capacidad de aprender y representar correctamente la relación entre las 30 características del dataset y la clasificación final (maligno vs benigno). Sesgo bajo es deseable porque indica que el modelo no es demasiado simplista (underfitting); puede capturar patrones complejos. El problema observado no es incapacidad de aprender, sino la capacidad de aprender demasiado bien los datos de entrenamiento incluyendo ruido y características idiosincráticas, lo cual es un problema de varianza, no de sesgo.

3. Detección Correcta del Grado de Varianza: Alto a Medio

Se detectó correctamente que el baseline tiene varianza alta (gap 8.8%) que se reduce a varianza media (gap 7.0%) con regularización, una reducción de 1.8 puntos porcentuales. La varianza alta en el baseline se evidencia por la caída catastrófica de 100% en entrenamiento a 91.2% en test, y por la curva de validación errática (Figura 3) que oscila entre 94-96%. Esto indica que el modelo sin restricción de profundidad memoriza ejemplos específicos de entrenamiento. Con regularización, el gap de 7.0% es mucho más razonable y controlado, y la curva de aprendizaje (Figura 4) es notablemente más suave y consistente, demostrando que el modelo regularizado es más estable y generaliza mejor. Esta reducción de varianza es el logro principal de la regularización.

4. Explicación Correcta del Nivel de Ajuste: Overfitting a Fitting Óptimo

El baseline claramente sufre de overfitting: alcanza 100% en entrenamiento pero solo 91.2% en test debido a que `max_depth=None` permite que los árboles crezcan sin restricción y se especialicen en datos de entrenamiento específicos. La Figura 5 lo visualiza claramente: conforme aumenta `max_depth`, el accuracy de entrenamiento sigue subiendo hacia 100%, pero el de validación se estabiliza alrededor de 96.2%, evidenciando que árboles más profundos solo memorizan. El modelo regularizado logra fitting óptimo: es flexible para aprender patrones reales (99.1% en entrenamiento confirma bajo sesgo) pero lo suficientemente simple para no memorizar ruido (7.0% gap es controlado). Este balance es el objetivo en machine learning, permitiendo predecir con confianza en casos nuevos.

5. Técnicas de Regularización Aplicadas Correctamente

Implementación de cuatro técnicas integradas:

- a. `Max_depth = 5` limita la profundidad de árboles, evitando especialización en datos específicos.
- b. `Max_features = 'log2'` introduce diversidad usando solo 5 características aleatorias por nodo en lugar de todas las 30.
- c. Validación cruzada 5-fold en `GridSearchCV` asegura selección robusta de hiperparámetros basada en múltiples splits, no en una sola división.
- d. Estratificación mantiene la proporción de clases en cada conjunto. Estas técnicas actúan sinérgicamente: `max_depth` reduce complejidad, `max_features` añade estabilidad al ensemble, CV reduce varianza en la selección de parámetros, y estratificación evita sesgos por distribución de clases. El resultado es un modelo más confiable que generaliza mejor, con test accuracy de 92.1% y gap controlado de 7.0%, permitiendo mayor confianza en su rendimiento con datos nuevos.